



# Clase 6:

# **Modelado Data-driven**




# Modelado Data-driven

- Motivación en el marco de la materia
- Vamos a hacer en los Colabs
- Reconstrucción de ODEs
  - Regresión
  - Regresión LASSO
  - SINDy
- Bibliografía

## Motivación en el marco de la materia

- Sistemas dinámicos = ODEs



**Cómo hago el proceso inverso?**


**Reconstrucción de ODEs**

## Vamos a hacer en los Colabs




- Reconstrucción de ODEs
  - Atractor de Lorenz
    - LASSO
    - SINDy
  - Oscilador de relajación de Van der Pol
    - Dificultades del método?


# Regresión



Regresión lineal





Regresión no lineal (polinomio, etc)



Propongo un **modelo** a partir del cual hay una **relación entre variables** (variables independientes y variables dependientes)

Estimo los **parámetros** que hacen que el **modelo** se **ajuste** a mis **datos**

## Regresión lineal




En datos reales tengo una componente aleatoria de ruido (puede ser natural)

Necesito resolver el sistema sobredeterminado

Voy a ajustar con una recta que no pasa exactamente por todos los puntos

# Regresión lineal



$$J(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \underbrace{(y^{(i)} - \hat{y}^{(i)})^2}_{\text{error}}$$

└─ Función costo

Variable dependiente

Variable independiente

Parámetros

$$Y_i = \beta_0 + \beta_1 X_i$$

Ajuste del modelo (estimación)

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$


Error cuadrático medio

**Ajustar** un modelo es básicamente resolver un problema de **optimización** que consiste en encontrar los **parámetros** que **minimizan una función costo**


# Regresión LASSO

## Regularización LASSO

$$J(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \underbrace{(y^{(i)} - \hat{y}^{(i)})^2}_{\text{error}} + \lambda \sum_{j=1}^M \|\hat{\beta}_j\|_p$$



Agregamos un término de **penalización** en la función costo



Cuando penalizo, es posible que parámetros se hagan cero (se cancelan términos)



# SINDy

Sparse Identification of Nonlinear Dynamical systems

Sistema dinámico  $\longrightarrow \frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t; \mu)$

Puedo plantear el campo vector como un desarrollo de variables en una base de transformaciones

$$\dot{\mathbf{X}} = \Theta(\mathbf{X})\Xi$$

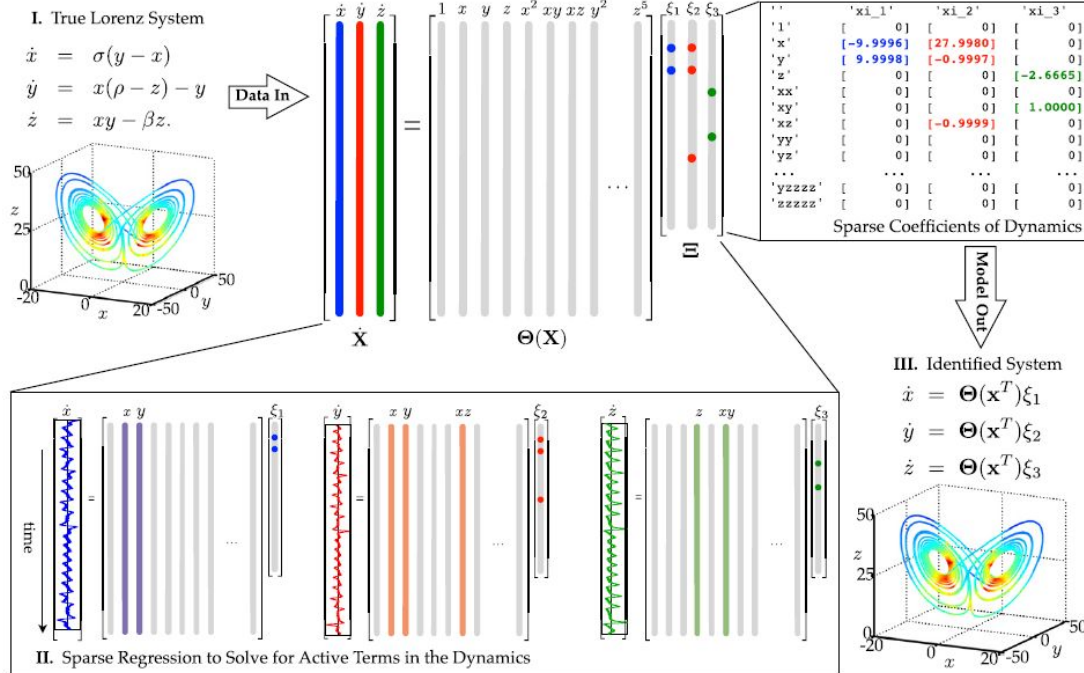
Derivadas  $\swarrow$   $\searrow$  Variables transformadas (por ejemplo  $x^2, z$ )  $\rightarrow$  Parámetros (coeficientes)

Si tengo las variables y sus derivadas, puedo hacer una regresión lineal

En particular, regresión de tipo LASSO, agrego penalización que selecciona parámetros y los hace 0

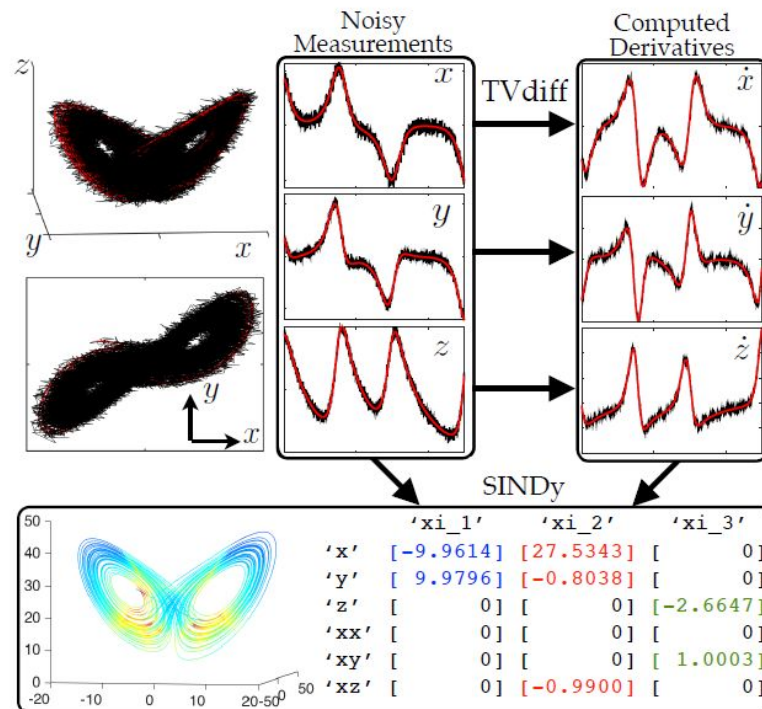
Puedo obtener una representación esparsa de las relaciones y reconstruir las ecuaciones del sistema

# SINDy



Brunton, Proctor, & Kutz (2016). *Discovering governing equations from data by sparse identification of nonlinear dynamical systems*. PNAS, 113(15), 3932-3937.

# SINDy




Funciona también

- para datos ruidosos
- cuando no tengo la derivada pero la puedo calcular numéricamente con cierta confianza


Qué limitaciones tiene esto?

Brunton, Proctor, & Kutz (2016). *Discovering governing equations from data by sparse identification of nonlinear dynamical systems*. PNAS, 113(15), 3932-3937.


## Bibliografía recomendada




Kutz 2013



Kutz et al 2016



Brunton & Kutz 2019



**towards**  
data science

